

Mini-projet de rattrapage (Data Mining) : Classification supervisée

1. Objectif

L'objectif de ce mini-projet est la création de deux modèles de classification supervisée, les K-plus proches voisins (KNN) et les Arbres de Décision, en appliquant les principes de l'apprentissage automatique sur un ensemble de données (Data Set).

La création d'un modèle de classification est un processus impliquant un ensemble d'étapes, à savoir : data understanding (compréhension des données), préparation de données, création et évaluation de modèles et finalement l'utilisation du modèle.

En réalisant ce mini-projet, vous allez ainsi mettre en pratique l'ensemble des principes théoriques de ce processus en utilisant le langage Python et son écosystème (ensemble de packages) dédié à la data science et l'apprentissage automatique (machine learning).

2. Organisation et déroulement

- Le travail doit être réalisé en **monôme**.
- Le mini-projet doit être réalisé sous forme d'un **Notebook** sous **Jupyter Notebook**.
- La remise des projets aura lieu au plus tard mardi **10 Février 2022**.
- Le **Notebook** (le fichier portant l'extension **.ipynb**) est le seul fichier à remettre.
- Veillez à bien présenter votre notebook en ajoutant des cellules de type **Text** et **Markdown**.

3. Ensemble des données (Data Set)

L'ensemble des données que vous allez utiliser au cours de ce mini-projet a été construit à partir des données de Rendez-vous médicaux de plusieurs patients. L'objectif est de prédire est ce que les patients se présenteront ou non à leur RDV.

L'ensemble des données est divisé en deux parties : ensemble d'apprentissage (**train.csv**) et ensemble de test (**test.csv**).

Voici le **dictionnaire** de l'ensemble des données :

Variable	Définition	Valeurs
PatientId	Identifiant du patient	
AppointmentID	Identifiant du RDV	
Gender	Sexe	F, M
ScheduledDay	Date de prise de RDV	
AppointmentDay	Date du RDV	
Age	Age	
Neighbourhood	Quartier	
Scholarship	Subvention de l'état brésilien	0=No, 1=Yes
Hipertension	Hypertension	0=No, 1=Yes
Diabetes	Diabète	0=No, 1=Yes
Alcoholism	Alcoolisme	0=No, 1=Yes
Handcap	Handicap	0=No, 1=Yes
SMS_received	SMS-reçu	0=No, 1=Yes
No-show	Non-présentation	No, Yes

4. Spécifications techniques

Le mini-projet doit être réalisé en respectant les exigences techniques suivantes :

- Langage de programmation : **Python**
- Environnement de développement : **Jupyter Notebooks**
- Calcul scientifique et manipulation des données : **numpy, scipy, pandas**
- Visualisation des données : **matplotlib, seaborn** ou autre
- Machine learning: **scikit-learn**

5. Spécifications fonctionnelles

Au cours de ce mini-projet vous allez aborder l'ensemble des étapes du processus d'extraction de connaissances à partir de données (ECD).

Alors, voici l'ensemble des exigences que vous devez satisfaire en réalisant ce mini-projet :

5.1. Data understanding :

- **Importation des Packages** du langage Python dédiés à la data science (voir spécifications techniques)
- **Chargement des ensembles de données** : l'ensemble d'apprentissage et l'ensemble de test
- **Fusion** des deux ensembles de données (train.csv et test.csv) pour créer un ensemble de données unique portant le nom « **dataset** ».
- **Affichage** des données : afficher un aperçu des 10 premières instances de l'ensemble de données « dataset ».
- **Description des données** de l'ensemble « dataset » : Afficher
 - Le **volume** (nombre d'instances) et la **dimension** des données (nombre d'attributs),

- Le **type** de codage des données
- Quelques **statistiques descriptives** (moyenne, quartiles, min, max, écart-type, ...) pour les **attributs numériques**
- Quelques **mesures statistiques** telles que le nombre de valeurs uniques, la fréquence d'apparition la plus élevée, etc. pour les **attributs catégoriels**.
- **Visualisation** des données : afin d'approfondir votre compréhension des données et chercher d'éventuelles **corrélations** entre la **variable cible** (la classe) et les autres attributs de l'ensemble d'apprentissage, vous êtes demandés de réaliser plusieurs types de graphiques (histogrammes, nuages de points, boîtes à moustaches, etc.).

5.2. Nettoyage des données

- Traitement des **valeurs manquantes** de l'ensemble des données « dataset » : afficher dans un tableau, le nombre de valeurs manquantes pour chaque attribut de l'ensemble de données. Sur la base de votre compréhension des données, proposer puis appliquer une technique de traitement des valeurs manquantes. Afficher un aperçu de l'ensemble des données pour prouver la disparition des valeurs manquantes.
- Traitement des **valeurs aberrantes** de l'ensemble des données « dataset » : Afficher dans un tableau, le nombre de valeurs aberrantes pour chaque attribut de l'ensemble de données. Sur la base de votre compréhension des données, proposer puis appliquer une technique de traitement des valeurs aberrantes. Pour chaque attribut faisant l'objet d'une ou de plusieurs valeurs aberrantes, proposer puis afficher un graphique mettant en évidence la disparition de ces valeurs.

5.3. Transformation des données

- Sur la base de votre compréhension des données, vous pouvez proposer, avec justification, de **supprimer** un ou plusieurs attributs que vous jugez non discriminants (pertinents) par rapport à la création du modèle de classification.
- Dans le but de faciliter l'application de certains algorithmes de machine learning, en l'occurrence l'algorithme des KNN, vous devez **transformer** toutes les données de type **catégorielles** en données **numériques**.
- **Normaliser si nécessaire** (avec justification) les valeurs des attributs de l'ensemble de données. Le cas échéant, afficher un aperçu de l'ensemble des données après l'application de la normalisation.

5.4. Création et optimisation des modèles

Après les étapes de compréhension et de préparation des données, il est temps de créer des modèles de classification supervisée.

L'objectif est de créer deux modèles de classification : les **KNN** (les plus proches voisins) et les **Arbres de Décision**. Ensuite, nous devons comparer leurs performances et choisir bien évidemment celui qui donne les meilleurs résultats de classification. La **performance** du modèle est estimée en calculant son **exactitude (Accuracy)**.

Pour atteindre cet objectif, vous devez :

- Diviser **l'ensemble des données « dataset »** en deux sous-ensembles : **80%** pour **l'apprentissage** (training data set) et **20%** pour le **test** (test data set).
- Ensuite, diviser le sous-ensemble d'apprentissage (training data Set) en deux sous-ensembles : **75%** pour **l'apprentissage** et **25%** pour la **validation**.
- **Ajustement des paramètres** (Fine tuning) : le but de cette étape est de choisir les valeurs les plus optimales pour les paramètres de chacun des deux modèles d'apprentissage (KNN et arbres de décision).

Alors, vous devez commencer par déterminer la liste des paramètres à optimiser (avec une liste de valeurs à tester pour chaque paramètre) pour chacun des deux modèles d'apprentissage.

Ensuite, vous devez créer, pour chaque algorithme d'apprentissage (KNN et Arbres de décision), plusieurs modèles dont le nombre dépend du nombre de paramètres à optimiser. Ces modèles doivent être créés sur la base de l'ensemble d'apprentissage (75%) et validés contre les données de l'ensemble de validation (25%).

Finalement, présenter dans un tableau l'ensemble des résultats obtenus pour chacun des deux modèles d'apprentissage en déterminant les valeurs des paramètres de chaque modèle créé et la valeur d'exactitude (accuracy).

- Comparer les performances (accuracy) des deux algorithmes (KNN et Arbres de décision) et en choisir le meilleur.

5.5. Test du modèle

Selon les résultats obtenus dans la phase précédente, vous devez appliquer le modèle de classification qui a donné la meilleure valeur d'exactitude (accuracy) sur l'ensemble de test (Test Data Set), afficher les résultats de classification ainsi que les mesures de performances suivantes :

- Exactitude (Accuracy)
- Matrice de confusion
- Précision
- Rappel
- F-score